Tire Tread Depth Estimation based on Standard Vehicle Dynamics

Kyoungtae Ji[a], Youngsam Yoon[b], Sehwan Ku[b], Jiyeon Hong[b], Yonghyun Ryu[b], Hyungjoo Kim[b], Jaekil Lee[b], Daeun Sung[b], Kyoungseok Han[a,*]

[a]*Department of Automotive Engineering, Hanyang University, South Korea*
[b]*Hyundai Motor Company, South Korea*

Abstract

We present a virtual tire tread depth sensor using only standard vehicle dynamics signals already available in modern vehicles. The key innovation is recognizing that worn tires exhibit measurably different vehicle dynamics—particularly in slip characteristics during braking—which can be captured through existing on-board sensors. We extract physics-based features from vehicle CAN bus data, with deceleration slip emerging as the dominant predictor. A stacking ensemble combining Random Forest, Gradient Boosting Machine, and Support Vector Regression is trained on real-world data from an electric taxi fleet. The system achieves coefficient of determination above 0.81 across all tire positions with average RMSE of 0.234 mm, demonstrating accuracy comparable to physical sensors while requiring zero additional hardware.

Keywords: Virtual sensing(가상 센싱), Tire tread depth estimation(타이어 트레드 깊이 추정), Machine learning(머신러닝), Feature selection(특징 선택), Ensemble learning(앙상블 학습), Vehicle dynamics(차량 동역학), On-board sensors(차량 탑재 센서)

1. 서론

타이어 트레드 깊이, 즉 타이어의 마모도는 차량의 안전성을 결정하는 핵심 요소임에도 불구하고, 현재의 모니터링 방법들은 고가의 하드웨어 센서를 필요로 하거나 정확도가 낮다는 한계를 가지고 있다. 기존 연구들은 카메라나 레이저를 활용한 직접 측정 시스템[**?**], 지속적인 이력 추적이 필요한 모델 기반 예측, 그리고 연속적인 회귀보다는 분류에 초점을 맞춘 기계학습 방법[**?**] 등으로 구분된다. 그러나 이러한 방법들은 추가 하드웨어 설치의 필요성, 제한적인 실험 환경에서의 검증, 또는 실제 도로 환경에서의 검증 부족 등의 문제를 안고 있다.

본 연구는 표준 차량 동역학 신호만을 활용하여 현재의 타이어 마모 상태를 추정하는 가상 센서 기술을 제안한다. 핵심 아이디어는 마모된 타이어가 정상 타이어와는 구별되는 차량 동역학 특성을 나타낸다는 점, 특히 제동 시 슬립 특성의 변화가 기존 차량 센서로 감지 가능하다는 점에 착안하였다. CAN 버스 데이터로부터 물리 기반 특징들을 추출한 결과, 감속 슬립이 가장 중요한 예측 인자임을 확인하였다.

본 연구에서는 5대의 전기 택시에서 타이어 전체 수명 주기 동안 수집한 실제 데이터를 활용하여 Random Forest, Gradient Boosting Machine, Support Vector Regression을 결합한 스태킹 앙상블 모델을 학습시켰다. 개발된 시스템은 모든 타이어 위치에서 $R^2 > 0.81$의 성능을 달성하였으며, 평균 RMSE는 0.234 mm로 추가 하드웨어 없이도 물리적 센서와 유사한 정확도를 보였다. 본 연구의 주요 기여는 다음과 같다: (1) 표준 차량 센서만을 이용한 가상 센싱 기술 구현, (2) 높은 정확도를 달성한 스태킹 앙상블 접근법, (3) 실제 운행 중인 택시 차량을 통한 실증적 검증.

figures/Vehicle_Standard_Sensors.png

Figure 1: 가상 타이어 마모 센싱에 활용되는 표준 차량 센서

2. 시스템 개요 및 문제 정의

최신 차량들은 안전 시스템을 위해 다양한 센서를 탑재하고 있으며, 이러한 센서들은 가상 타이어 트

*Corresponding author
Email address: kyoungsh@hanyang.ac.kr (Kyoungseok Han)

레드 깊이 센싱에 필요한 모든 데이터를 제공한다. 본 연구의 접근법은 물리적 센서를 추가로 설치하는 대신, 타이어 마모에 의해 발생하는 차량 동역학의 변화를 기존 센서로 감지하는 것이다. Figure 1에 나타난 바와 같이, IMU(3축 가속도 및 요 레이트), 개별 휠 속도 센서(슬립 비율 계산), 조향각 센서, 제동 압력 센서, TPMS, 모터 토크 추정, 외기 온도 센서 등이 핵심 센서로 활용된다. 이러한 소프트웨어 기반 솔루션은 추가 하드웨어 비용이 없으며, 별도의 센서 설치나 유지보수가 불필요하다는 장점을 가진다.

2.1. 타이어 트레드 깊이와 차량 동역학에 미치는 영향

타이어 트레드 깊이는 차량의 안전과 성능을 좌우하는 핵심 파라미터이다. Figure 2는 세 가지 마모 단계에서 타이어 폭 방향의 트레드 깊이 분포를 보여준다. 외측 가장자리(GV1)부터 내측 가장자리(GV6)까지 6개 위치에서 측정한 결과, 신품 타이어의 약 7 mm에서 마모 타이어의 4 mm 이하로 감소하는 특징적인 마모 패턴이 관찰된다. 이러한 점진적 감소는 타이어와 노면 간의 상호작용을 근본적으로 변화시켜 차량 동역학에 측정 가능한 영향을 미친다.

figures/tire_wear_pattern_lines-eps-converted-to.pdf

Figure 2: 세 가지 마모 단계에서의 타이어 폭 방향 트레드 깊이 분포. 외측(GV1 Out)부터 내측(GV6 In)까지 6개 홈 위치에서 측정된 결과는 신품에서 마모 상태로의 점진적 깊이 감소를 보여줌

트레드 깊이 감소가 차량 동역학에 영향을 미치는 물리적 메커니즘은 타이어 역학 문헌에서 잘 정립되어 있다[**?** **?** **?**]. 주요 영향은 다음의 네 가지로 요약된다:

첫째, 타이어 접촉 패치의 기하학적 형상이 마모에 따라 크게 변화한다. 최근 실험 연구에 따르면 마모된 타이어는 접촉 길이는 감소하지만 접촉 폭은 증가하는 특성을 보인다. 트레드 홈이 사라지면서 실제 접촉 면적이 증가하여 힘 생성 메커니즘이 근본적으로 변화한다. 이러한 접촉 패턴의 변화는 가감속 시 슬립 특성에 직접적인 영향을 미쳐 측정 가능한 차량 동역학적 차이를 만든다.

둘째, 트레드 깊이 감소에 따라 타이어 강성이 증가한다. 브러시 모델 이론에 의하면[**?**], 전단 강성은 트레드 블록 높이에 반비례한다. 실험 측정 결과 종방향 및 횡방향 강성이 마모에 따라 현저하게 증가함이 확인되었다[**?**]. 이러한 강성 변화는 코너링 특성과 이완 거리를 변화시켜 요 레이트 응답과 횡가속도에서 구별되는 신호를 생성한다.

셋째, 타이어 마모에 따라 마찰-슬립 관계가 진화한다. 증가된 접촉 면적과 높아진 강성의 조합은 타이어의 힘 생성 특성을 변화시킨다. 마모된 타이어는 신품 타이어와 다른 최대 마찰계수를 생성하며 변형된 슬립-힘 곡선을 나타낸다. 이러한 변화는 타이어가 마찰 한계 근처에서 작동하는 코너링, 제동, 가속과 같은 동적 기동 시 가장 명확하게 나타난다.

넷째, 구름 반경 감소는 마모에 따라 비선형 패턴을 따른다. 최근 연구에 따르면 구름 반경은 트레드 깊이 감소보다 느린 속도로 감소하며, 직접 비례가 아닌 비선형 관계를 따른다[**?**]. 이러한 비선형성은 휠 속도 센서 판독값에 영향을 미치고 마모된 타이어와 신품 타이어 간의 감지 가능한 회전 속도 차이를 생성한다.

이러한 물리적 변화들은 표준 차량 센서로 포착 가능한 차량 동역학 데이터의 독특한 신호를 생성한다. 최근 연구들은 이러한 관계를 실증적으로 검증하였으며, 슬립 특성이 타이어 마모에 따라 측정 가능하게 변화하고 슬립 기반 특징이 강력한 분류 능력을 보인다는 것을 입증하였다[**?**]. 이러한 동역학 신호를 분석함으로써 직접적인 물리적 측정 없이도 현재의 트레드 깊이를 추론할 수 있다.

2.2. 물리 기반 특징 설계

본 연구의 특징 공학 접근법은 타이어 마모가 측정 가능한 차량 동역학 변화를 통해 나타난다는 기본 원리에 기반한다. 미리 정의된 특징 세트에 제한되지 않고, 표준 차량 신호로부터 얻을 수 있는 주요 주행 특성들을 포괄적으로 추출한다. 이러한 체계적 접근법은 특징 선택 기법을 적용하기 전에 알고리즘의 효과를 검증할 수 있게 한다.

특징 추출 과정은 차량-타이어 상호작용의 물리학을 활용한다. 주요 주행 특성들은 영향 인자들로 정규화되어 의미 있고 비교 가능한 메트릭을 생성한다[**?**]:

- **코너링 동역학**: 횡가속도 게인과 요 레이트 게인은 조향 입력에 대한 차량 응답을 정규화한다:

$$G_{ay} = \frac{a_y}{\delta} \tag{1}$$

$$G_{\psi} = \frac{\dot{\psi}}{\delta} \tag{2}$$

  여기서 a_y는 횡가속도, $\dot{\psi}$는 요 레이트, δ는 조향 핸들 각도이다. 이러한 정규화는 운전자의 조향 의도에 대한 순수한 차량 응답을 분리해내어, 마모된 타이어가 기본적인 코너링 특성을 어떻게 변화시키는지를 효과적으로 드러낸다. 조향 크기의 영향을 제거함으로써, 이 메트릭들은 마모된 타이어의 증가된 강성으로 인한

변화된 동적 응답 특성을 노출시키며, 이는 신품 타이어와 다른 게인 특성으로 나타난다.

- **종방향 동역학**: 가속 및 감속 이벤트 동안의 슬립 비율은 구동축과 비구동축 속도를 사용하여 계산된다:

$$s = \frac{v_{ref} - v_{driven}}{v_{ref}} \tag{3}$$

여기서 v_{ref}는 비구동 휠의 기준 속도, v_{driven}은 구동 휠의 속도이다[?]. 이 비율들은 타이어-노면 마찰 특성을 직접적으로 나타낸다.

- **경로 추적**: 경로 곡률은 조향 입력과 무관하게 차량의 실제 궤적을 특징짓는다:

$$\kappa = \frac{\dot{\psi}}{v} \tag{4}$$

여기서 v는 차량 종방향 속도이다. 이 메트릭은 타이어 마모 상태에 따라 변화하는 차량의 고유 안정성과 응답 특성을 포착한다.

위에서 설명한 코너링, 종방향, 경로 추적 메트릭들은 타이어 거동의 전 스펙트럼을 포착하기 위해 다양한 운행 조건별로 추가적으로 계층화된다. 타이어 동역학이 속도에 따라 크게 변하므로 특징들은 서로 다른 속도 범위별로 계산된다. 마찬가지로 약한, 중간, 강한 회전이 서로 다른 마모 민감도를 보이므로 조향 이벤트는 크기별로 분류된다. 비대칭 마모 패턴을 감지하기 위해 좌회전과 우회전 특성이 독립적으로 계산되며, 평균, 표준편차, 백분위값을 포함한 통계적 집계는 일반적 거동과 극단적 이벤트를 모두 포착한다.

전기차의 경우, 견인력과 무게 지표를 정밀하게 계산할 수 있게 하는 모터 토크 기반 특징들을 추가로 포함한다. 온도와 타이어 공기압과 같은 환경 요인들도 타이어 거동에 미치는 영향을 보정하기 위해 포함된다[?]. 이러한 포괄적인 물리 기반 특징 추출 전략은 타이어 마모 상태에 따라 변화하는 차량 동역학의 핵심 측면들을 포착한다.

3. 실험 방법론

3.1. 시스템 아키텍처

Figure 3는 데이터 수집, 오프라인 학습, 온라인 추정의 세 가지 주요 단계로 구성된 가상 타이어 마모 감지 시스템의 전체 아키텍처를 보여준다.

데이터 수집 단계에서는 차량 운행 중 연속적으로 취득되는 차량 동역학 데이터와 주기적으로 측정된 실제 트레드 깊이를 결합한다. 이렇게 동기화된 데이터셋은 특징 추출 과정을 거쳐 포괄적인 마모-주행 관계를 생성한다. 오프라인 학습 단계에서는 Random Forest, Support Vector Regression, Gradient Boosting의 세 가지 상호보완적인 머신러닝 알고리즘을 활용하며, 각 모델의 하이퍼파라미터는 5-fold 교차 검증을 통한 베이지안 최적화로 결정된다. 이들의 예측값은 앙상블 학습을 통해 결합되어 강건한 메타 모델을 생성한다. 학습된 모델은 온라인 추정 단계를 가능하게 하며, 여기서 실시간 차량 센서 데이터가 동일한 특징 추출 파이프라인을 거쳐 물리적 측정 없이도 연속적인 트레드 깊이 추정값을 제공한다.

3.2. 데이터셋 설명

실험 데이터셋은 약 1년간 도심 환경에서 운행한 5대의 전기 택시 차량으로부터 수집되었다. 사계절 타이어를 장착한 이 상업용 차량들은 완전한 타이어 수명 주기(차량당 25,000-30,000 km) 동안 모니터링되어, 높은 일일 주행거리를 누적하는 까다로운 운영 조건 하에서 실제 마모 패턴을 제공했다. 전체 데이터셋은 동기화된 차량 동역학 데이터와 실측 트레드 깊이를 포함하는 1,160개 샘플로 구성되며, 이를 812개의 학습 샘플과 347개의 테스트 샘플로 분할했다.

각 차량은 ±0.15 mm 정밀도의 디지털 깊이 게이지를 사용하여 매달 트레드 깊이를 측정하였다. 산업 표준에 따라 각 타이어의 트레드 폭 전반에 걸쳐 미리 정의된 위치에서 6개의 홈 깊이를 측정했으며, 평균값을 대표적인 마모 지표로서 활용하였다. 물리적 측정 사이의 날짜에 대해서는 누적 주행거리를 기반으로 선형 보간을 적용했는데, 이는 타이어 마모가 안정적인 마모 단계에서 주로 선형적 거동을 보인다는 연구 결과에 근거한다[? ?].

모니터링 기간 동안 각 차량은 완전한 타이어 교체 주기를 겪었으며, 타이어는 일반적으로 25,000–30,000 km의 집중적인 도심 주행 후 교체되었다. 이를 통해 신품 타이어(7–8 mm 트레드 깊이)부터 교체 임계값(약 3 mm)까지의 전체 스펙트럼을 포착하는 다중 마모 진행 데이터셋을 확보했다. 이러한 포괄적인 범위는 모델 학습 데이터가 실제 운영에서 마주치는 모든 마모 상태를 포함하도록 보장한다.

연속적인 차량 동역학 데이터는 모니터링 기간 내내 차량의 진단 인터페이스를 통해 20 Hz로 기록되었다. 데이터는 필터링을 거쳐 건조한 노면 조건만 포함되도록 했으며, 와이퍼 작동 신호와 주변 온도 임계값을 사용하여 젖거나 빙판 조건을 제외했다.

3.3. 머신러닝 모델 및 스태킹 앙상블

타이어 마모 예측의 본질적인 복잡성과 비선형성을 다루기 위해, 우리는 세 가지 상호보완적인 회귀 알고리즘을 기본 모델로 사용한다. Random Forest (RF)는 이상치에 대한 강건성과 명시적 특징 공학 없이 비선형 특징 상호작용을 포착하는 능력 때문에 선택되었다[?]. Gradient Boosting Machine (GBM)은 순차적 오류 수정 능력을 제공하며 다양한 스케일과 중요도 수준을 가진 특징들을 다루는 데 뛰어나다[?]. Support Vector Regression (SVR)은 구조적 위험 최소화에 기반한 근본적으로 다른 학습 패러다임을 제공함으로써 트리 기반 방법들을 보완하며, 특히 부드럽고 연속적인 관계에 효과적이다[?]. 이러한 다양한 알고리즘들은 마모-특징 관계의 서로 다른 측면을 포착하며, 하이퍼파라미터는 5-fold 교차 검증과 함께 30회 반복의 베이지안 최적화를 사용하여 최적화된다.

figures/Overview.png

Figure 3: 가상 타이어 트레드 깊이 추정을 위한 시스템 아키텍처. 시스템은 세 단계로 구성됨: (1) 플릿 주행 데이터와 실측 트레드 깊이 측정값을 결합하는 데이터 수집, (2) 앙상블 방법을 사용한 예측 모델 훈련을 위한 오프라인 학습, (3) 표준 차량 센서로부터 실시간 트레드 깊이 모니터링을 가능하게 하는 온라인 추정.

세 기본 모델의 상호보완적 강점을 활용하기 위해, 우리는 데이터로부터 최적 결합 가중치를 학습하는 스태킹 앙상블 접근법을 사용한다[?]. 핵심은 5-fold 교차 검증의 out-of-fold (OOF) 예측을 사용하여 메타 학습기를 훈련시키는 것으로, 해당 샘플에 대해 훈련되지 않은 모델로부터 예측이 나오도록 하여 과적합을 방지한다. 각 기본 모델은 교차 검증을 통해 OOF 예측을 생성하고, 이들은 각 모델에 대한 최적 가중치 β_j를 학습하는 선형 메타 학습기에 의해 결합된다. 학습된 가중치는 Random Forest가 가장 크게 기여하고(타이어 위치별로 40-65%), Support Vector Regression (28-37%)과 Gradient Boosting Machine (26-37%)이 상호보완적인 예측을 제공함을 보여준다. 이 접근법은 각 타이어 위치에 특화된 데이터 기반 결합 가중치를 학습함으로써 단순 평균법을 일관되게 능가한다.

새로운 테스트 샘플 x_{test}에 대해, 앙상블 예측은 다음과 같이 계산된다:

$$\hat{y}_{ensemble} = \beta_0^* + \beta_{RF}^* \hat{y}_{RF} + \beta_{GBM}^* \hat{y}_{GBM} + \beta_{SVR}^* \hat{y}_{SVR} \quad (5)$$

여기서 $\hat{y}_j = \mathcal{M}_j(x_{test})$는 모든 가용 학습 데이터로 훈련된 최종 기본 모델들의 예측이고, β^*는 학습된 메타 모델 가중치이다.

이 스태킹 아키텍처는 표본 내 예측으로 메타 모델을 훈련할 때 발생할 수 있는 과적합 문제를 피하면서 다양한 예측을 효과적으로 결합한다.

우리는 처음에 임의로 도출한 백여 개 이상의 물리 기반 특징을 사용하여 모델을 훈련시킨 후, 순열 중요도와 상관 분석을 적용하여 가장 중요한 20개 특징을 식별했다. 감속 슬립의 우세(37.7% 중요도)는 타이어 물리학과 일치하며, 트레드 깊이가 감소한 마모된 타이어는 제동 이벤트 중 증가된 슬립을 보인다. Figure 4은 모든 샘플에 걸친 평균 트레드 깊이와 감속 슬립 비율 간의 이러한 핵심 관계를 보여준다.

figures/tread_slip_all_tires-eps-converted-to.pdf

Figure 4: 평균 트레드 깊이와 차량 감속 슬립 비율 간의 관계.

4. 실험 결과

4.1. 실험 설정

실험은 5대의 전기 택시에서 수집한 1,160개 샘플(동기화된 차량 동역학 데이터와 트레드 깊이 측정값)을 사용했다. 70/30 학습-테스트 분할을 통해 812개의 학습 샘플과 347개의 테스트 샘플로 나누었으며, 5대 차량 모두의 데이터가 양쪽 세트에 포함되도록 세그먼트 단위로 무작위 분할했다.

모든 실험은 MATLAB R2024a에서 구현되었다. 각 기본 모델의 하이퍼파라미터 최적화는 30회 반복의 베이지안 최적화를 활용했다. 5-fold 교차 검증 전략[?]을 모든 실험에 일관되게 적용하여 공정한 비교와 강건한 성능 추정을 보장했다.

4.2. 모델 성능 비교

앙상블 접근법의 효과를 평가하기 위해, 먼저 선택된 20개 특징으로 학습된 개별 기본 모델의 성능을 평가했다. Table 1는 네 개의 타이어 위치 모두에 대한 Random Forest, Gradient Boosting Machine, Support Vector Regression의 테스트 세트 RMSE 값을 제시한다.

Table 1: Individual model performance (Test RMSE).

Model	All Tires
Random Forest	0.2846
Support Vector Regression	0.2779
Gradient Boosting Machine	**0.2611**

결과는 GBM이 가장 낮은 평균 RMSE (0.2611)를 달성하고, SVR (0.2779)과 RF (0.2846)가 그 뒤를 따르는 것을 보여준다. 모델 간 성능 차이는 각 모델이 타이어 마모-동역학 관계의 상호보완적인 측면을 포착함을 시사한다. 스태킹 앙상블 접근법은 이러한 다양한 예측을 결합하여 최종 결과에서 보여지듯이 우수한 성능을 달성한다.

4.3. 최종 앙상블 결과

Table 2는 선택된 특징을 사용한 최종 앙상블 모델의 포괄적인 테스트 세트 성능을 제시한다.

Table 2: Ensemble model performance on test set.

Tire Position	RMSE	R^2
FL (Front Left)	0.1562	0.8129
FR (Front Right)	0.2076	0.8233
RL (Rear Left)	0.2775	0.8158
RR (Rear Right)	0.2945	0.8135
Average	**0.2339**	**0.8164**

모든 타이어 위치에서 $R^2 > 0.81$을 달성하여, 실제 배치를 위한 목표 임계값 0.80을 초과했다. 전륜 타이어는 후륜 타이어에 비해 낮은 RMSE 값(< 0.21)을 보이는데, 이는 주로 후륜 구동 차량에서 전륜 타이어가 전체적으로 더 적은 마모를 경험하여 마모 범위가 감소했기 때문이다. 예측당 단 0.145

ms의 추론 시간으로, 시스템은 계산 제약 없이 실시간 배치를 가능하게 한다. 이러한 결과는 표준 차량 센서의 동적 특징을 사용한 가상 센싱이 물리적 트레드 깊이 센서에 필적하는 정확도를 달성할 수 있음을 확인한다.

Figure 5은 후륜 구동 테스트 차량에서 가장 예측이 어려운 경우를 나타내는 후륜 우측 타이어 위치의 실제 대 예측 트레드 깊이 값을 산점도로 시각화하여 예측 정확도를 보여준다.

figures/scatter_plot_RR_20features-eps-converted-to.pdf

Figure 5: 테스트 세트에서 최종 앙상블 모델을 사용한 후륜 우측 (RR) 타이어 위치의 실제 대 예측 평균 트레드 깊이(mm) 비교 산점도.

산점도는 신품 타이어부터 마모된 타이어까지 전체 마모 스펙트럼에 걸쳐 예측 정확도가 일관되게 유지됨을 보여준다. 표시된 후륜 우측 위치는 후륜 구동 차량의 더 큰 마모 변동으로 인해 가장 높은 예측 난이도를 나타낸다. 이러한 도전에도 불구하고, 모델은 서로 다른 마모 수준에서 체계적인 편향을 보이지 않으며, 점들이 대각 기준선 주위에 균등하게 분포되어 있다.

5. 결론

본 연구는 표준 차량 센서만을 사용하여 하드웨어 비용을 제거한 가상 타이어 트레드 깊이 추정 시스템을 제시한다. 스태킹 앙상블 접근법은 감속 슬립을 주요 특징(37.7% 중요도)으로 하여 모든 타이어 위치에서 $R^2 > 0.81$을 달성한다. 시스템은 추가 센서 설치 없이 플릿 관리 애플리케이션을 위한 실시간 트레드 깊이 모니터링 기능을 제공한다.

모델은 전기 택시 플릿 데이터를 사용하여 개발되었으며, 마모 특성을 포착하기 위해 충분한 주행 동역학이 필요하다. 향후 연구는 플랫폼 간 적응을 위한 전이 학습과 잔여 타이어 수명 예측을 위한 예측 정비 시스템과의 통합을 탐구해야 한다.